

다차원. 4차원 → regression. ?

선형 회귀. 이렇다.

regression ← new feature
(새로운 개념).

3. Classification

분류

복숭아 수확 기계

model → predict → 결과

0.5 ↑ → True

0.5 ↓ → False



https://cdn.ppomppu.co.kr/zboard/data3/2021/0103/20210103221124_ebzlkcr a.mp4

- http://m.ppomppu.co.kr/new/bbs_view.php?id=humor&no=423793
- 익은 복숭아 vs 안익은 복숭아
- 크기, 물렁도, 색깔, ...



차원에 따른 분류 문제

직선을 이용한 분류 문제 해결

이 크기



차원에 따른 분류문제 해결법



- **Bottom Step:** 대부분의 레이블 값이 $y_p = 0$ 인 점들을 포함합니다.
- **Top Step:** 대부분의 레이블 값이 $y_p = +1$ 인 점들을 포함합니다.
- **분리**
 - $N = 1$ 일 때는 점으로, $N = 2$ 일 때는 선으로, $N > 2$ 일 때는 초평면 (hyperplane)으로 대부분 분리된다.


Classification with Probability

- 확실성을 가지고 예측할 수 없는 많은 상황에서, 어떤 사건이 발생할 확률을 예측하는 데 유용하기 위해서는 어떻게 해야 할까?
- 예시: 암 예측, 주식/비트코인 가격 예측, 날씨 예측 등.

Continuous Output


- 출력 y 는 0과 1 사이에서 연속적으로 변화한다.
- y 가 1에 가까울수록 어떤 사건이 발생할 가능성이 높다.

기준: 0.5 $\text{model}(x_i) > 0.5 \Rightarrow \text{True 판독}$
 $\text{model}(x_i) \leq 0.5 \Rightarrow \text{False 판독}$



- **Soft Binary Classification):**

- 소프트 레이블(확률, 0 ~ 1)을 반환한다.
- Probability Regression: 출력을 [0, 1] 범위로 제한한다.



Function1 : Step function

$\text{model}(\text{Value}) \Rightarrow 2.3 \Rightarrow 1$ (True)
 $\text{model}(\text{Value}) \Rightarrow 0.3 \Rightarrow 0$ (False)

$$\text{step}(x) = \begin{cases} 1 & \text{if } x \geq 0.5 \\ 0 & \text{if } x < 0.5 \end{cases}$$

- 선형 경계: 두 클래스 간의 경계는 선형이며, 모든 점 x 에 대해 $w_0 + xw_1 = 0.5$ 로 정의됩니다.

$\text{model} = w_0 + xw_1$
 $\text{model}(x_0) = w_0 + x_0w_1$
 경계

- N차원 입력에 대한 모델

- N차원 입력에 대한 선형 모델: 일반적인 N차원 입력을 위한 선형 모델은 다음과 같이 표현된다.

$x = [1 \ x_1 \ x_2 \ \dots \ x_N]$ $w = [w_0 \ w_1 \ w_2 \ \dots \ w_N]$
 $xw^T = w_0 + x_1w_1 + x_2w_2 + \dots + x_Nw_N$ $w^T = \begin{bmatrix} w_0 \\ w_1 \\ w_2 \\ \vdots \\ w_N \end{bmatrix}$
 step function과의 결합: 해당 선형 결합에 단계 함수를 적용하면 $\text{step}(xw^T)$ 와 같다.

$x \cdot w^T = \rightarrow \downarrow = w_0 + x_1w_1 + \dots$

파라미터 조정

- 파라미터 조정의 목표

- 적합한 가중치 설정
- 분류기는 최종적으로 레이블이 +1인 점은 $x^T w > 0.5$ 인 양의 영역, 레이블이 0인 점은 $x^T w < 0.5$ 인 음의 영역에 위치하도록 분류해야 한다.

이것은 문제. 크기

- 이를 통해 각 점의 step ($\mathbf{x}^T \mathbf{w}$) 에 대한 예측값이 해당 점의 Label 값과 일치하도록 한다.


- Cost function

$$w_0 + w_1 x_1 + w_2 x_2 = \text{model}(\text{이것})$$

$$E(\mathbf{w}) = \frac{1}{2} \sum_{p=1}^P (\text{step}(\mathbf{x}^T \mathbf{w}) - y_p)^2$$

문제점

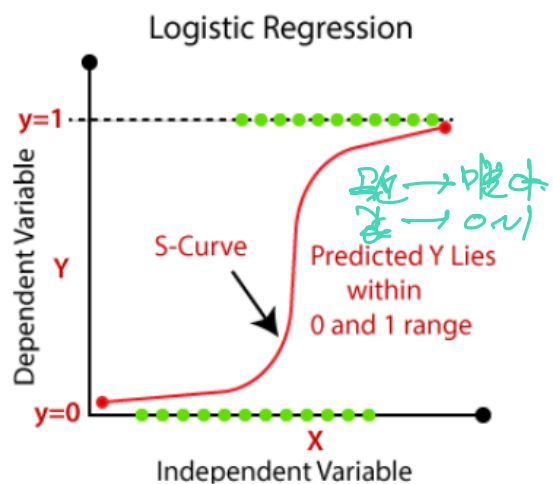

- 최소 제곱 비용의 이산성
 - $E(\mathbf{w})$ 의 결과는 정수 값만을 취한다. 따라서 미분값이 모두 0 이다. 따라서 경사하강법 적용 불가
- Step function의 불연속성
 - Step function 은 불연속 함수이다. 따라서 Cost function도 불연속적인 성질을 갖고 있다.



Function2 : Logistic Function, Sigmoid Function

- 선형 함수 $s = \mathbf{w}^T \mathbf{x} + b$ 를 0과 1 사이로 제한하는 함수.
- Sigmoid 함수 $\sigma(s)$ 는 $\sigma(s) = \frac{1}{1+e^{-s}}$ 로 정의된다.
- 입력 s 는 $[-\infty, +\infty]$, 출력은 $[0, 1]$ 범위.

$$s \Rightarrow \frac{1}{1+e^{-s}}$$



Step function

$\rightarrow 0$, or False
 $\rightarrow 1$, or True

Sigmoid function

$0 < \frac{1}{1+e^{-s}} < 1 \rightarrow$ 확률 나타냄

확률 0
확률 1

$$\sigma(s) = \frac{1}{1+e^{-s}} \quad \lim_{s \rightarrow -\infty} \frac{1}{1+e^{-s}} = 0$$

$$\lim_{s \rightarrow +\infty} \frac{1}{1+e^{-s}} = 1$$

odd → logit → sigmoid
 ↓
 softmax

선형 회귀의 비용 함수

선형 회귀에서는 최소 제곱 오차(LSE, Least Squares Error) 기준을 사용합니다. 이는 모델이 예측한 값과 실제 값 사이의 차이의 제곱합으로 정의됩니다. 선형 회귀의 비용 함수는 다음과 같이 표현됩니다:

$$J_{\text{linear}}(\mathbf{w}) = \frac{1}{2P} \sum_{p=1}^P (y_p - \mathbf{x}_p^T \mathbf{w})^2$$

로지스틱 회귀와 최소 제곱 오차의 문제점

- 로지스틱 회귀에 선형 회귀와 같은 LSE 기준을 그대로 적용하면, 비용 함수는 다음과 같다

회귀 → sigmoid 적용 → MSE 적용


non-convex

$$J_{\text{logistic}}(\mathbf{w}) = \frac{1}{2P} \sum_{p=1}^P (y_p - \sigma(\mathbf{x}_p^T \mathbf{w}))^2$$

sigmoid

$$\frac{1}{1 + e^{-\mathbf{x}_p^T \mathbf{w}}}$$


- 비용 함수는 비볼록(non-convex) 형태가 되어, 로컬 최소점(local optima)에 빠질 위험이 있다.



Logistic regression Costfunction

- 정의:** Log Error의 Cost function는 출력은 y_p 가 1 또는 0일 때 다음과 같이 정의됩니다
 - y_p : p 에서의 y 값
 - $h_w(\mathbf{x}_p) = \sigma(\mathbf{x}_p^T \mathbf{w}) = \frac{1}{1 + e^{-\mathbf{x}_p^T \mathbf{w}}}$



$$\text{cost}(h_w(\mathbf{x}_p), y_p) = \begin{cases} -\log(h_w(\mathbf{x}_p)) & \text{if } y_p = 1 \\ -\log(1 - h_w(\mathbf{x}_p)) & \text{if } y_p = 0 \end{cases}$$




- Simplification form

Cross entropy : loss function.

$$\text{cost}(h_w(\mathbf{x}_p), y_p) = -y_p \log(h_w(\mathbf{x}_p)) - (1 - y_p) \log(1 - h_w(\mathbf{x}_p))$$






Logistic regression Costfunction

- 로지스틱 회귀에서는 교차 엔트로피 비용 함수를 사용한다.

$$J_{\text{logistic}}(\mathbf{w}) = -\frac{1}{P} \sum_{p=1}^P [y_p \log(\sigma(\mathbf{x}_p^T \mathbf{w})) + (1 - y_p) \log(1 - \sigma(\mathbf{x}_p^T \mathbf{w}))]$$

특징


- $y_p = 1$ 일 때, $\sigma(\mathbf{x}_p^T \mathbf{w})$ 가 1에 가까울수록 비용은 감소한다
 - $y_p = 0$ 일 때, $\sigma(\mathbf{x}_p^T \mathbf{w})$ 가 0에 가까울수록 비용은 감소한다
- 최대 우도 추정(Maximum Likelihood Estimation) 기준을 따른다
- 볼록 함수(Convex)로, 전역 최소점(global minimum)을 찾는 것이 가능하다



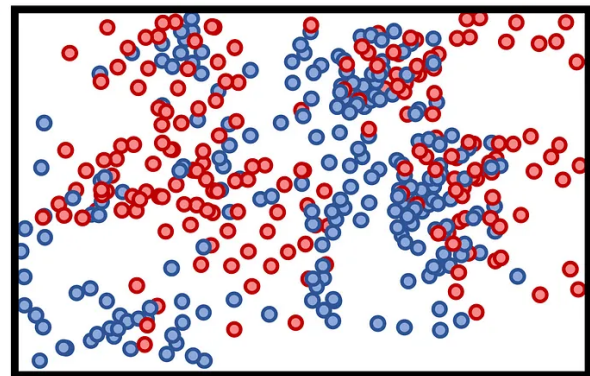
예측(Prediction)

- 클래스 선택: 더 높은 확률을 가진 클래스가 선택된다.
 - 양성 Class : $P(y_i = 1|x_i) = \theta(w^T x_i + b)$
 - 음성 Class : $P(y_i = -1|x_i) = 1 - \theta(w^T x_i + b)$

교차 엔트로피 비용 함수



Low Entropy



High Entropy

- 정의:** 교차 엔트로피 비용 함수는 모든 데이터 포인트에 대한 로그 오류 비용의 평균으로 정의된다.

$$J(\mathbf{w}) = \frac{1}{P} \sum_{p=1}^P cost_p(\mathbf{w})$$

- 등가 표현:** 로그 오류를 하나의 식으로 결합한 형태

$$J(\mathbf{w}) = -\frac{1}{P} \sum_{p=1}^P [y_p \log(\sigma(\mathbf{x}_p^T \mathbf{w})) + (1 - y_p) \log(1 - \sigma(\mathbf{x}_p^T \mathbf{w}))]$$

- 가중치 조정:** 이 비용 함수는 가중치 \mathbf{w} 가 적절하게 조정되었을 때 최소값에 도달합니다.
- 최적화:** 로지스틱 회귀에서의 최적화에 적합하며, 이진 분류 문제에 유용합니다.

~~linear regression~~ \Rightarrow regression
 \hookrightarrow logistic regression \Rightarrow classification
 sigmoid
 cross-entropy

Cost function

Model Evaluate