4.5 Batch

Batch

도입

D/L : 병렬처리. M/L: CPU 순차적.

- 우리가 사용하는 데이터는 벡터화 되어 병렬 처리 된다.
- $X = [x^1, x^2, x^3, \ldots, x^{100}, \ldots, x^{5000}]$
- $Y = [y^1, y^2, y^3, \ldots, y^{100}, \ldots, y^{5000}]$

$x' = [x'_{(1)}, x'_{(2)}, x'_{(3)}, \ldots, x'_{(n)}]$

x' Data는 n개의 feature (특징).

y' : x'에 대한 정답.

1000개 ~

실제 처리되는 데이터의 단위는 어떻게 될까?

- 데이터가 너무 많음! 메모리 부족
- 한번 계산으로 최적화(optiization) 하기는 너무 어렵다. m
- 여러번 학습시키기 위해 데이터를 나눈다.

Iteration.

데이터를 나누기 위한 단위

Epoch (반복한 단위 Iteration)

- 전체 sample 데이터를 이용하여 한 바퀴 돌며 학습하는 것을 1회 epoch이라 한다.
- 예) 2 epochs은 전체 sample을 이용하여 두 바퀴를 돌며 학습한 것이다.

Step

1 Epoch에 1Step   1 Epoch에 2step

- Weight와 Bias를 1회 업데이트하는 것을 1 Step이라 부른다.

예) 문제집 → 전체 → 정답 : 1epoch. 1step

문제집 절반 → 정답
〃 → 정답] 1epoch. 2step

Batch Size

- 1 Step에서 사용한 데이터의 수이다.

- 예) Batch Size가 100이라고 가정하고 Step이 5이면 약 500개의 데이터를 이용한 것이다.

관계

아래와 같은 관계가 성립한다.

s = (n * e) / b

n = num of sample : 전체 학습할 데이터의 개수

e = epochs: Epoch 수

b = batch size: 배치 사이즈

s = steps: Step 수

벡터화 ⇒ m개의 연산 ⇒ 병렬처리 가능

$X = [x^{(1)} \; x^{(2)} \; x^{(3)} \; \cdots \; x^{(m)}]$
(n_x, m)

$Y = [y^{(1)} \; y^{(2)} \; y^{(3)} \; \cdots \; y^{(m)}]$
$(1, m)$

$m = 5{,}000{,}000$ 개라면?

훈련 세트를 더 작은 훈련 세트로 나눈다면?

mini 훈련 세트를 batch 라고 한다. 1step에 들어가는 batch를 mini batch 라고한다

$$X = [\underbrace{x^{(1)}, x^{(2)}, \cdots, x^{(1000)}}_{X^{(1)}} \,|\, \underbrace{x^{(1001)}, \cdots, x^{(2000)}}_{X^{(2)}} \,|\, \cdots]$$

$$Y = [\underbrace{y^{(1)}, y^{(2)}, \cdots, y^{(1000)}}_{Y^{(1)}} \,|\, \underbrace{y^{(1001)}, \cdots, y^{(2000)}}_{Y^{(2)}} \,|\, \cdots \underbrace{\cdots, y^{(m)}}_{Y^{(5000)}}]$$

각각 1000개씩, 5000개의 mini batch가 존재.
$X^{(1)}, X^{(2)}, \cdots, X^{(5000)}$

$X^{(i)}$ 의 차원은 $(n_x, 1000)$ n_x : x의 차원 (feature의 개수)
$Y^{(i)}$ 의 차원은 $(1, 1000)$

Batch Size 에 따른 Gradient Descent 과정

- Gradient Descent 의 Update 과정은 다음과 같이 이루어 지고 있다.
- Batch Size (m) 에 따른 학습률 변화는 어떻게 이루어 질까?

Cost Function – "One Half Mean Squared Error":

평균

$$J(\theta_0, \theta_1) = \frac{1}{2m}\sum_{i=1}^{m}\left(h_\theta\left(x^{(i)}\right) - y^{(i)}\right)^2$$

배치 개수로 나눔

Objective:

$$\min_{\theta_0, \theta_1} J(\theta_0, \theta_1)$$

Update rules:

$$\theta_0 := \theta_0 - \alpha\frac{\partial}{\partial\theta_0}J(\theta_0, \theta_1)$$

$$\theta_1 := \theta_1 - \alpha\frac{\partial}{\partial\theta_1}J(\theta_0, \theta_1)$$

Derivatives:

$$\frac{\partial}{\partial\theta_0}J(\theta_0, \theta_1) = \frac{1}{m}\sum_{i=1}^{m}\left(h_\theta\left(x^{(i)}\right) - y^{(i)}\right)$$

$$\frac{\partial}{\partial\theta_1}J(\theta_0, \theta_1) = \frac{1}{m}\sum_{i=1}^{m}\left(h_\theta\left(x^{(i)}\right) - y^{(i)}\right)\cdot x^{(i)}$$

$$\frac{1}{2m}\sum^{m}\left(\qquad \right)^2$$ N : 전체

Gradient Descent(Full Batch Gradient Descent)

- 일반적으로 GD 라고 알려진 방식은 Full Batch Gradient Descent 를 의미 한다.
- Batch Size = m = 전체 를 의미함.
- Batch Size 가 m 이면 1개의 Batch만 존재하고 1Epoch 당 1Batch 가 학습되어 Update 됨.

Stochastic Gradient Descent

- Batch Size = m = 1 (랜덤으로 추출된 1개의 데이터 사용)
- Vector 연상의 장점이 사라지고 한개의 학습 데이터씩 가중치가 업데이트 된다.
- 가중치가 빠르게 업데이트 되므로 학습의 속도가 빨라진다.
- 상대적으로 적은 Epoch 가 사용됨

전체

Mini Batch Gradient Descent

CLM. = Model ↑ GPU

- Batch Size = m = n

Batch Size : 1

- 2^n개로 Batch Size 를 지정해 준다. (2진법적인 관점)

⇒ 1 epoch 6시간. 12시간

- 미니 배치 확률적 경사하강법은 SGD의 노이즈를 줄이면서도 전체 배치보다는 더 빠르게 최적점을 구할 수 있습니다.

9B.

90%

Aa Property	경사하강법	확률적 경사하강법
1회의 학습에 사용되는 데이터	모든 데이터 사용	랜덤으로 추출된 1개의 데이터 사용(중복 선택 가능)
반복에 따른 정확도	학습이 반복 될 수록 최적해에 근접	학습이 반복 될 수록 최적해에 근접
노이즈	거의 없음	비교적 노이즈가 심함

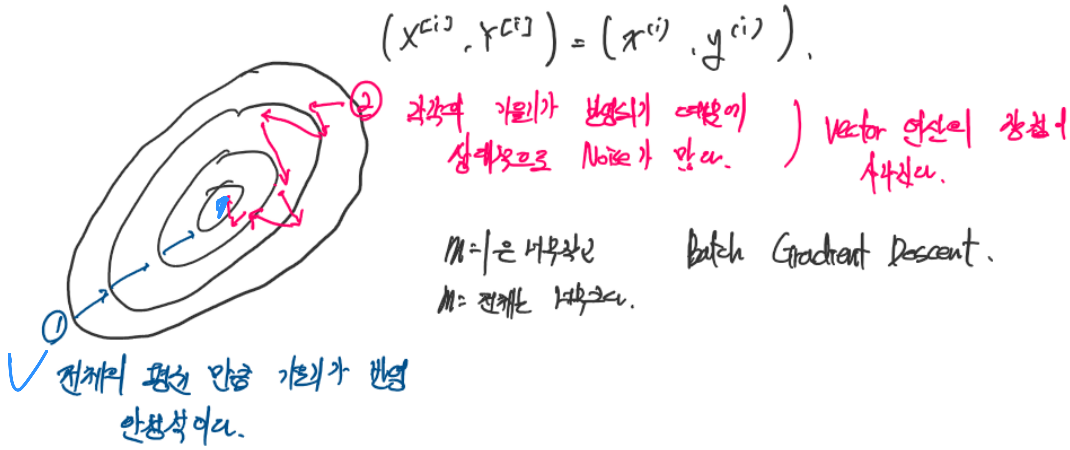


```
model.compile(optimizer='adam', loss='sparse_categorical_cros
history = model.fit(train_X, train_Y, epochs=5, batch_size=16
```

참고자료

https://www.ritchieng.com/machine-learning-large-scale/