

3.5 출력층 설계하기

도입

- Output 을 위한 Node에는 어떠한 Activation Function 이 들어가야 할까?
- 점수로 나타낸다면?
 - softmax? 항등함수? 상관없을까?
- 분류를 위한 확률로 나타낸다면?
 - 관상 App
 - 성격 Test App

회귀

- 입력데이터에 대한 수치를 예측하는 문제
- 값을 예측하기 위함이므로 항등함수를 주로 사용한다.

분류


- 입력데이터에 대한 분류
- 어느 Class 에 속할 확률을 나타내기 위함이므로 확률에 관련된 Function 을 사용한다.

분류를 위한 출력함수

- 분류를 위한 가장 좋은 출력값을 어떤 형태이어야 할까?
 - 정수 $(-\infty, \infty)$
 - 확률 $(0,1)$


함수에 따른 Output

Score




Sigmoid Function

- 확률 x
- 단순히 (0,1) 의 값



Softmax Function

- 확률 o
- 총합이 1 인 값



Sigmoid, Logit and Softmaxsoftmax와 sigmoid


Class1 과 Class2 의 분류

- 이진 분류



odd(승산)

- 성공할 확률을 p 라 할때, 실패 대비 성공할 비율을 승산 이라고 한다.
- $odd = \frac{p}{1-p}$
- 예
 - Chelsea 의 승리 11, 패배 2 일때 첼시의 패배 확률은?
 - 첼시의 패배 확률 : $\frac{p}{1-p} = \frac{2}{11}$ 이므로 $p = \frac{2}{13}$
 - 첼시의 승리 확률 : $\frac{p}{1-p} = \frac{11}{2}$ 이므로 $p = \frac{11}{13}$



logit Function

- odd 에 밑이 e 인 log 함수를 취한값

$$\begin{aligned}
 z &= \ln \left(\frac{p}{1-p} \right) \\
 \Leftrightarrow e^z &= \frac{p}{1-p} \Leftrightarrow \frac{1}{e^z} = \frac{1-p}{p} = \frac{1}{p} - 1 \\
 \Leftrightarrow \frac{1}{e^z} + 1 &= \frac{1}{p} \Leftrightarrow e^{-z} + 1 = \frac{1}{p} \\
 \Leftrightarrow \frac{1}{e^{-z} + 1} &= p. \quad \text{Sigmoid}(z) = p = \frac{1}{e^{-z} + 1} \quad \text{제로 역함수.} \\
 \text{logit}(p) &= \ln \left(\frac{p}{1-p} \right).
 \end{aligned}$$

softmax Function

- softmax 함수는 sigmoid의 일반형
- Class가 N 개인 경우 odd 를 이용해 $logit$ 을 표현하면 다음과 같이 표현할수 있다.
-

C_1, C_2, \dots, C_N N개의 class에 대하여.

x 가 C_k 에 속할 확률에 대한 x 가 C_i 에 속할 확률은 $\exp(z_i) = \frac{p(C_i|x)}{p(C_k|x)}$ — ①

x 가 C_k 에 속할 확률은 $\frac{\sum_{j=1}^K p(C_j|x)}{p(C_k|x)} = \sum_{j=1}^K \exp(z_j)$

$$= \frac{1 - p(C_k|x)}{p(C_k|x)} = \sum_{j=1}^K \exp(z_j)$$

$$\Leftrightarrow \frac{1}{p(C_k|x)} - 1 = \sum_{j=1}^K \exp(z_j)$$


$$\Leftrightarrow p(C_k|x) = \frac{1}{\sum_{j=1}^K \exp(z_j) + 1} = \frac{1}{\sum_{j=1}^K \exp(z_j) + \exp(z_k)} = \frac{1}{\sum_{j=1}^K \exp(z_j)}$$

$$\therefore p(C_k|x) = \frac{1}{\sum_{j=1}^K \exp(z_j)}$$

①의 위의 보수를 대입.

$$\exp(z_i) = p(C_i|x) / p(C_k|x)$$

$$\exp(z_i) / \sum_{j=1}^K \exp(z_j) = p(C_i|x)$$



정리

$$\begin{aligned}
 P(C_1|x) &= y \\
 P(C_2|x) &= 1 - y \\
 \text{Choose } \begin{cases} C_1 & \text{if } y > 0.5 \\ C_2 & \text{if } y \leq 0.5 \end{cases} &\Leftrightarrow \frac{y}{1-y} > 1 \Leftrightarrow \log_e \frac{y}{1-y} > 0
 \end{aligned}$$

odds log + odds = **logistic** + probit = **logit**

$$\text{logit}(y) = \log_e \left(\frac{1}{1-y} \right) = t$$

$$= \frac{y}{1-y} = \exp(t)$$

$$= \frac{1}{y} - 1 = \frac{1}{\exp(t)}$$

$$= \frac{1}{y} = \frac{1+\exp(t)}{\exp(t)}$$

$$= y = \frac{\exp(t)}{1+\exp(t)}$$

$$= y = \frac{1}{1+\exp(-t)}$$

$$= \text{Sigmoid}(t)$$

$$\therefore \text{logit}(y) = t, \text{Sigmoid}(t) = y$$

$$\begin{aligned}
 C_1, C_2, \dots, C_K \quad & \frac{P(C_i|x)}{P(C_K|x)} = \exp(t_i) \\
 \sum_{j=1}^{K-1} \frac{P(C_j|x)}{P(C_K|x)} &= \sum_{j=1}^{K-1} \exp(t_j) \\
 = \frac{1 - P(C_K|x)}{P(C_K|x)} &= \sum_{j=1}^{K-1} \exp(t_j) \\
 = P(C_K|x) &= \frac{1}{1 + \sum_{j=1}^{K-1} \exp(t_j)} \\
 P(C_i|x) &= \exp(t_i) \cdot P(C_K|x) \text{에 } P(C_K|x) \text{ 대입} \\
 = \frac{\exp(t_i)}{1 + \sum_{j=1}^{K-1} \exp(t_j)} &= \frac{\exp(t_i)}{\exp(t_K) + \sum_{j=1}^{K-1} \exp(t_j)} \quad (\because 1 = \frac{P(C_K|x)}{P(C_K|x)} = \exp(t_K)) \\
 \therefore \frac{\exp(t_i)}{\sum_{j=1}^K \exp(t_j)} &= \text{softmax}(t_i)
 \end{aligned}$$

logit

softmax

sigmoid

derive simple case inverse

general case